

Распознавание модуляции с низким уровнем NRR на основе глубокого обучения в программно-определяемом радио

Хусам АЛЗАК-ОСМАНОВ
ЛУ

Кафедра вычислительной техники

Бирунинского

университета

Истабул, Турция

<https://orcid.org/0000-0002-1027-2945>

Джилан АЛРЕХАЙЛИ

Факультет компьютерной

инженерии Стамбульского

технического университета

Истабул, Турция

alrehaili16@itu.edu.tr

B. Berk USTUNDAG

Факультет компьютерной

инженерии Стамбульского

технического университета

Истабул, Турция

bustundag@itu.edu.tr

Аннотация. Автоматическая классификация модуляции (AMC) и распознавание (AMR) принимаемых беспроводных сигналов играют важную роль в различных областях коммерческой и военной деятельности. Эти методы позволяют определить тип модуляции и распознать принимаемый сигнал путем извлечения из него дискриминационных признаков. Глубокие нейронные сети (ГНС) являются отличным инструментом для идентификации модуляции сигнала, поскольку способны извлекать сложные признаки из принимаемых сигналов. В данной работе мы предлагаем модель конволюционной сети для классификации типа модуляции беспроводного сигнала при низких значениях SNR. Результаты экспериментов показывают, что предложенная модель правильно классифицирует 72% цифровых сигналов при -4 дБ. Точность может быть увеличена, если уменьшить сходство между QAM4 и QAM64, 8PSK и QPSK.

Индексные термины - когнитивная радиосвязь, глубокая нейронная сеть, цифровая обработка сигналов

свойств и определения на их основе компактных границ принятия решений с использованием либо аналитически выведенных границ принятия решений, либо статистически изученных границ в низкоразмерных пространствах признаков [3], [4]. Точность моделирования на основе изученных признаков может быть повышена путем тщательного подбора соответствующего набора признаков, а также применения новых методов извлечения признаков.

Поскольку традиционные методы распознавания модуляции, например PSK и ASK, обычно требуют предварительного знания параметров сигнала и канала для точной классификации принимаемого сигнала и распознавания передаваемых данных [5], [6], машинный

978-1-6654-5054-6/22/\$31.00 ©2022 IEEE

I. ВВЕДЕНИЕ

В последние годы для классификации и определения типа модуляции передаваемого сигнала широко применяется автоматическое распознавание модуляции (AMR, также известное как классификация модуляции (AMC)). В то время как передатчик может свободно использовать любой тип модуляции, приемник использует AMC для определения типа модуляции и связанных с ним параметров по принимаемому сигналу. AMC имеет ряд военных и гражданских применений, таких как анализ и управление спектром, идентификация передатчиков и анализ угроз [1]. Кроме того, AMC становится неотъемлемой частью интеллектуальных программно-определяемых радиостанций (SDR) для связи 5G [2].

AMC является важной задачей для полной информированности о беспроводной среде в когнитивном радио (КР). По мнению Тима О'Ши и др., AMC решается путем ручной разработки специализированных экстракторов признаков для определенных сигналов,

Алгоритмы обучения стали одной из ключевых возможностей АМК во многих приложениях. В литературе для АМК применяется множество методик и алгоритмов, таких как искусственная нейронная сеть (ИНС), скрытая марковская модель (СММ), нечеткое логическое управление, метаэвристические алгоритмы (эволюционный/генетический алгоритм) и системы на основе правил [7], [8], [18]. В настоящее время постепенно внедряются сверточные нейронные сети (CNN) [10], [11].

В данной статье не представлен новый подход АМК для сигналов радиосвязи с использованием CNN, но сделан акцент на прямом обучении признаков на основе простых представлений беспроводных сигналов без необходимости ручного создания экспертных признаков. В предыдущих работах, посвященных методам АМК, рассматривалась эффективность при средних значениях SNR, например, более 2 дБ. В данной работе показано, что CNN обеспечивает хорошую эффективность классификации даже при низких значениях SNR сигнала, не превышающих 2 дБ.

Основной вклад данной работы заключается в возможности обнаружения и распознавания различных сигналов при низких значениях SNR без построения новых схем демодуляции для каждого типа модуляции. Мы исследуем, как различные методы CNN могут быть использованы для разработки алгоритмов обнаружения для систем связи, которые обучаются непосредственно на основе данных. Благодаря CNN мы показываем, что эти алгоритмы достаточно устойчивы, чтобы выполнять обнаружение при очень низких значениях SNR, не зная базовых моделей канала, что особенно эффективно в зашумленных каналах или при наличии помех связи.

Изложение данной работы построено следующим образом. Раздел

В разделе II описаны АМК и глубокая нейронная сеть. В разделе III представлен метод, используемый в данной работе. В разделе IV представлен анализ результатов моделирования, а в разделе V приведены выводы.

II. РАСПОЗНАВАНИЕ МОДУЛЯЦИИ В SDR

Автоматическое распознавание модуляции (АРМ) - это, по сути, задача классификации, которая используется для классификации различных видов модуляции неизвестных сигналов без вспомогательной информации на стороне приемника. Существуют две категории традиционных алгоритмов АМК: метод, основанный на оценке правдоподобия, и метод ручного выделения признаков с помощью искусственного интеллекта (ИИ), основанный на экспертном опыте [11], [15].

Классификация слепой модуляции (СМ) на основе статистических данных [16], таких как классификация по правдоподобию (LB) и классификация по максимуму апостериори (Maximum a Posteriori).

(MAP) подходы требуют предварительного знания параметров сигнала и канала для точной классификации принятого сигнала и распознавания перенесенных данных. Например, для получения исходной двоичной информации при неизвестных амплитуде, фазе и мощности шума требуется всего две точки принятия решения на приемнике двоичной фазовой манипуляции (BPSK).

В качестве альтернативы существующим статистическим подходам были предложены алгоритмы на основе искусственного интеллекта и глубокого обучения (ГСО) [2], [17]. Эти методы позволяют автоматически выделять из принимаемых сигналов сложные и подходящие для конкретного применения признаки. А. Нанди *и др.* используют искусственные нейронные сети (ИНС) для распознавания аналоговой и цифровой модуляции [5]. Y. Ettefagh *и др.* представляют адаптивную систему выделения признаков и мультиклассификации с использованием ИНС с последующей системой голосования для обеспечения устойчивости алгоритма [12]. Основным недостатком использования ИНС является способ извлечения признаков из принимаемого сигнала. Другая проблема связана с его низкой точностью при низких значениях SNR [18].

Благодаря сверточным нейронным сетям (CNN) задача поиска новых признаков, пригодных для классификации при различных SNR, была решена с большим успехом не только для определения типа модуляции, но и для извлечения данных [10], [11], [14], [19], [20]. Например, В. Пенг *и др.* [11] разработали архитектуру, основанную на сети Inception-ResNet, изменив несколько размеров ядра и время повторения модулей для адаптации к классификации модуляции. Y. Wang *и др.* [14] предлагают алгоритм на основе глубокого обучения, который в сочетании с двумя CNN, обученными на разных наборах данных, позволяет достичь более высокой точности AMR.

В связи с тем, что метод модуляции многоканальных сигналов сложнее, чем одноканальных, исследователи часто комбинируют CNN с алгоритмом LSTM, как в [20], [21]. X. Лю *и др.* исследуют гибридные архитектуры глубоких нейронных сетей для АМК [20], включающие сверточную нейронную сеть (CNN), остаточные сети (ResNet), сверточную сеть с плотными связями (DenseNet) и сверточную глубокую нейронную сеть с длинными и короткими связями (CLDNN). Точность классификации гибридной модели без каких-либо модификаций структуры сети ограничена. Хуанг *и др.* В работе [21] для идентификации модуляций предложена рекуррентная остаточная сеть (GrrNet), состоящая из трех модулей: выделения признаков на основе ResNet, объединения признаков и классификации на основе GRU. Эта сеть использует внутрикласовую компактность и межкласовую разделимость, используя ограничение на сжимающие потери, для повышения точности определения цифровых модуляций высшего порядка.

В большинстве упомянутых методик неявно предполагается, что сигнальные компоненты имеют достаточно высокие значения SNR, чтобы их можно было четко отличить от шумов заднего плана, определяемых шумовым полом приемника. Однако при низких значениях SNR их эффективность существенно снижается. В данной работе рассматривается влияние низкого значения SNR на различение типов модуляции.

III. ПРЕДЛАГАЕМАЯ МЕТОДИКА ГЛУБОКОГО ОБУЧЕНИЯ

Основной целью данной работы является адаптация сверточной нейронной сети (CNN) к реальному радиосигналу с комплексным значением для распознавания и классификации модуляции сигнала на приемнике. Ключевая роль приемника заключается в обнаружении, дискриминации и последующем распознавании принимаемых беспроводных сигналов [12].

В реальных условиях принимаемый сигнал может быть нечетким или неясным. Более того, из-за большого расстояния проблема может детерминироваться при низких значениях SNR, что ограничивает возможности приемника по распознаванию принимаемого сигнала. Точность модели приемника повышается по мере того, как обучаемые признаки принимаемых сигналов улавливают все более локальные и тонкие детали принимаемого сигнала. В этом разделе мы более подробно рассмотрим методы классификации радиосигналов в приемнике.

A. Конволюционная нейронная сеть

Конволюционные нейронные сети (КНС) [22] являются очень мощными архитектурами глубокого обучения (ГОО), которые достигают очень высокой производительности при анализе изображений и видео, таких как обработка изображений [23], обнаружение объектов [24], распознавание лиц [25], обнаружение заболеваний листьев растений [26] и распознавание символов рукописного текста [27]. CNN также демонстрируют огромные перспективы в области идентификации и классификации радиосигналов в различных беспроводных приложениях. В данной работе мы применяем CNN для решения задачи классификации различных типов модуляции сигнала благодаря его способности точно определять различные паттерны сигнала.

В общем случае CNN представляет собой особую форму нейронной сети с прямолинейным движением и одним или несколькими скрытыми слоями, называемыми конволюционными. Конволюционный слой выполняет процесс фильтрации поступающего на вход сигнала, что позволяет выявлять сложные паттерны сигналов.

Модели CNN [22], [28] состоят из одного или нескольких сверточных слоев (conv), затем слоя объединения и полностью связанных слоев (FC), как показано на рис. 1. В то время как сверточный слой используется для извлечения дискриминационных признаков сигналов и обнаружения полезных паттернов, полностью связанными слоями реализуют регрессионную карту от признаков к целевым меткам. Объединение слоев позволяет снизить вычислительную нагрузку между последовательными конволюционными слоями за счет уменьшения числа связей и размеров карт признаков.

B. Модель извлечения признаков

Модуль выделения признаков в предлагаемой модели состоит из трех иерархических слоев свертки и функции максимального объединения, которые в совокупности вычисляют репрезентацию признаков входного сигнала, как показано на рис. 1. Эти слои объединяются для выделения главного признака принятого IQ-сигнала. По сути, сверточные слои расширяют традиционную искусственную нейронную сеть, добавляя к входу предыдущих слоев увеличенную глубину и дополнительные ограничения. В общем случае выполняется свертка двумерного ядра и входной карты,




Рис. 1. Модель извлечения признаков.

в любой конкретной пространственной координате (x, y) , представляет собой сумму точечных произведений следующим образом

$$conv_{x,y} = \sum_i w_i \cdot v_i \quad (1)$$

где w_i - веса конволюционного ядра, а v_i - значения соответствующих пространственных протяженностей на входной карте. Выход конволюционного слоя получается путем добавления скалярного смещения b

$$z_{x,y} = conv_{x,y} + b \quad (2)$$

Для достижения наилучшей производительности мы предлагаем использовать три одинаковых конволюционных слоя, последовательно соединенных друг с другом. Каждый слой имеет 256 фильтров размером 1×3 . Этот метод позволяет сети игнорировать малозначимые параметры (т.е. вес и смещение) конволюционных слоев.

После каждого сверточного слоя подключается объединяющий слой, который объединяет соседние сверточные нейроны в один выходной нейрон с последующим уменьшением размерности. На рис. 1 показаны максимальные операции объединения или функции, вычисляемые над короткими непересекающимися срезами сверточных нейронов. Операции объединения сверток обычно выполняются для извлечения сложного представления признаков входной последовательности. Кроме того, добавление в сеть слоев свертки-пулинга позволяет извлекать сложные паттерны взаимодействия, увеличивая при этом сложность сети, что может отражать поведение принимаемых сигналов.

С. Классификационная модель

Модель классификации используется для классификации признаков, полученных на предыдущем этапе. В принципе, после извлечения соответствующих признаков из принимаемого сигнала, классификация этих признаков в соответствующие классы позволяет распознать сигнал и тип модуляции. В данной статье добавляется один плоский слой и три полностью связанных слоя, как показано на рис. 2.

На рис. 2 показано, что предлагаемая модель имеет один плоский слой, поскольку плоская обработка данных помогает преобразовать двумерную матрицу признаков в вектор, который может быть подан в полносвязный классификатор. Наконец, третий плотный полносвязный слой подключен к выходному слою, который способен





Рис. 2. Сеть классификации сигналов.



предсказать тип модуляции.

В каждом плотном слое предлагаемой модели используется функция активации rectified linear unit (ReLU), состоящая из 128 нейронов. С другой стороны, в выходном слое используется функция активации Softmax. Таким образом, последний плотный слой и выходной слой имеют одинаковое количество нейронов, что эквивалентно 8

классы. В общем случае функция активации Softmax представляет собой сжимающую функцию, которая ограничивает выход функции в диапазоне $[0, 1]$. Это позволяет интерпретировать выход непосредственно как вероятность [28].

IV. РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТОВ

A. Набор данных

Набор данных, используемый в данном исследовании, был сгенерирован с помощью GNU Radio [3] и имеет размер 3,5 ГБ. Этот набор данных RADIOML 2016.10A содержит 1024 выборки с 1 200 000 точками данных и 10 типов модулированных сигналов с соответствующими значениями SNR от -20 дБ до +18 дБ. В данном исследовании использовались 8 видов цифровой модуляции: BPSK, 8-PSK, CPFSK, GFSK, PAM4, QAM16, QAM64, QPSK. Для имитации реальных условий сигнала набор данных был построен с помощью иерархического блока GNU Radio Dynamic Channel Model, который включает в себя различные эффекты, такие как смещение частоты дискретизации (SRO), смещение центральной частоты (CFO), селективные замирания (SF) и AWGN [29].

B. Обучение и тестирование

Имеющийся набор данных RADIOML должен использоваться для решения двух задач: обучения (тренировки) признаков и последующего тестирования (оценки) модели. Обучающий набор используется для построения модели в автономном режиме, а тестовый набор - для оценки точности модели в режиме онлайн, как показано на рис. 3. Для этого набор данных делится на 80% для обучения и 20% для тестирования, что подчиняется принципу Парето [30]. Другими словами, набор данных RADIOML был разделен на 960000 образцов для обучения и 240000 для тестирования. Кроме того, для учета случайности и исследования согласованности сигналов проводится 10-кратная кросс-валидация. Для ранней остановки применяется функция обратного вызова со значением терпения 15, которая автоматически останавливает обучение, как только потери при валидации или скорость обучения перестают улучшаться.

C. Сравнительная оценка

Для оценки точности классификации сигналов мы используем показатель успешности распознавания символа как индикатор эффективности работы приемника по правильному распознаванию принятого




Рис. 4. Зависимость точности от значений SNR

символов [18]. Он показывает способность обученной модели классифицировать полученные символы в тестовом наборе, которые ранее не встречались. Он также выражает вероятность правильной классификации и вычисляется следующим образом:

$$SuccessRate = \frac{1}{N} \sum_i x_i * 100 \quad (3)$$

где N - общее количество тестовых символов, а x_i - показатель того, правильно ли распознан символ i^{th} . Другими словами, коэффициент успешности измеряет коэффициент ошибок символов (SER).

На рис. 4 показана общая точность предлагаемой работы при различных значениях SNR, полученных с помощью 3. Из рисунка 4 также видно, что точность высока в диапазоне от 1 дБ до 18 дБ. Ниже -7 дБ точность составляет менее 50%.

Для оценки общей точности модели в определении класса модуляции применяется метод F_1 . F_1 объединяет точность и отзыв, как показано в упр. 4.

$$F_1 = 2 * \frac{Precision * Recall}{Precision + Recall} \quad (4)$$

Точность и отзыв рассчитываются, как показано в уравнениях 5 и 6

$$точность = \frac{T_p}{T_p + F_p} * 100 \quad (5)$$

$$отзыв = \frac{T_p}{T_p + F_n} * 100 \quad (6)$$

где T_p - истинно положительное значение, при котором модель правильно предсказывает положительный класс, F_p - ложноположительное значение, при котором модель неправильно предсказывает положительный класс, и F_n - ложноотрицательный результат, при котором модель неправильно предсказывает отрицательный класс. То есть, чем выше показатель F_1 , тем меньше ложноположительных и ложноотрицательных результатов, так что модель правильно идентифицирует реальный тип модуляции и не путается с другими типами модуляции. Показатель F_1 считается идеальным, если он равен




Рис. 5. Зависимость оценки F_1 от SNR.




Рис. 6. Матрица смещения при значениях SNR от -12 до -6 дБ.

D. Точность классификации при различных значениях SNR

В этом разделе мы покажем точность классификации для каждого из них.

вид модуляции при различном значении SNR. Мы предпочитаем разделить их на три группы. Это классификация при очень низких значениях SNR (ниже -6 дБ), при низких значениях SNR (от -2 дБ до 4 дБ) и при высоких значениях SNR (выше 6 дБ).

1. Аналогично, при значении 0 модель является полностью неудачной [28].

На рис. 5 показана оценка F_1 для каждого типа модуляции. На нем видно, что при SNR, равном -8 дБ, оценка F_1 для CFSK, BPSK, PAM4 и CPFSK примерно равна 0,75, в то время как классификаторы остальных видов модуляции достигают одинаковой оценки F_1 в районе -1 дБ.

На рис. 6 и 7 показаны матрицы путаницы для каждого вида модулированного сигнала, включая 8PSK, BPSK, CPFSK, GFSK, PAM4, QAM16, QAM64 и QPSK при различных значениях SNR. Матрицу смещения можно объяснить как таблицу, которая регулярно используется для отображения эффективности модели классификации. Она позволяет наглядно представить эффективность работы алгоритма.

На рис. 6 показана точность классификации каждого модулированного сигнала при очень низких значениях SNR. Из рисунка видно, что при очень низком значении SNR наилучшей точностью среди других видов модуляции обладает модуляция PAM4. Результаты показывают, что модель классификации ошибочно классифицирует QAM16 и QAM64 из-за большого сходства между классами.

На рис. 7 показана точность классификации при низких значениях SNR, например, при -4, -2, 0 и 2 дБ соответственно. Видно, что точность повышается, в основном, для BPSK, CPFSK, GFSK.




Рис. 7. Матрица запутанности при значениях SNR от -4 до +2 дБ.

и PAM4. Для QAM16 и QAM64, а также 8PSK и QPSK модель по-прежнему частично не различает каждую из них из-за взаимного сходства. На самом деле модель успешно различает каждую группу, т.е. QAM или PSK. Однако для достижения хороших результатов необходимо увеличить межсимвольное сходство между каждым классом.

Наконец, на рис. 8 показана точность классификации при средних значениях SNR, например, при 4, 6, 8 и 10 дБ соответственно. Это свидетельствует о повышении точности и исчезновении несходства между классами.




Рис. 8. Матрица запутанности при значениях SNR от +2 до +10 дБ.

Е. Вычислительная сложность

В табл. I приводится сравнение текущего результата с базовым результатом CNN, чистой ResNet, чистой Inception, LSTM и сети MentorNet на наборе данных RML2016b при различных уровнях SNR. При значении SNR -4 дБ предложенный в [11] метод и текущая модель имеют более высокую точность по сравнению с другими моделями. При приближении значения SNR к 4 дБ точность текущей модели достигает 92,9%.

В табл. II приведено сравнение вычислительной сложности предложенной модели с другими методами. Суммарные параметры указывают на количество параметров в различных моделях, т.е. весов. Из табл. II видно, что количество суммарных параметров в предлагаемой сети меньше, чем во всех моделях.

V. ЗАКЛЮЧЕНИЕ

В данной работе мы описали экономичную и высокопроизводительную глубокую CNN для автоматической классификации модуляции путем автоматического извлечения признаков сигналов различных схем модуляции. Мы проанализировали производительность CNN при различных низких значениях SNR. В экспериментах предложенный подход достигает 72,3% при SNR -4 дБ. Совершенно очевидно, что предложенный алгоритм обеспечивает более высокую точность для всех рассмотренных схем модуляции при -4 дБ и выше при большом количестве выборок. Таким образом, улучшается производительность при низких значениях SNR.

Результаты данного исследования помогут построить новые модели, эффективно различающие различные виды модуляции при низких значениях SNR. Кроме того, построенная модель CNN быстро работает на приемнике, поскольку отсутствует фаза обучения. Благодаря развитию микросхем искусственного интеллекта, приложения реального времени, требующие низких задержек или высокоскоростных коммуникаций, смогут воспользоваться преимуществами этой модели за счет уменьшения битовых ошибок, возникающих при низких значениях SNR. В результате дальнейшее развитие предлагаемой работы заключается в улучшении производительности за счет использования глубокого автокодировщика для определения уровня SNR и применения генеративных адверсарных сетей (GAN) перед текущей CNN для различения схожей модуляции, такой как QAM16 и QAM64, что может повысить точность.

ССЫЛКИ

- [1] L. Weng, Y. He, J. Peng, J. Zheng, and X. Li, "Deep cascading network architecture for robust automatic modulation classification," *Neurocomputing*, vol. 455, pp. 308-324, 2021. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231221007219>
- [2] L. Вонг и А. Майклс, "Трансферное обучение для машинного обучения радиочастот: Таксономия и обзор", *Sensors*, vol. 22, no. 1416, стр. 11 734-11 753, 2022.
- [3] T. O'Shea and N. West, "Radio machine learning dataset generation with gnu radio", *Proceedings of the GNU Radio Conference*, vol. 1, no. 1, 2016. [Online]. Available: <https://pubs.gnuradio.org/index.php/grcon/article/view/11>
- [4] T. J. O'Shea, T. Roy, and T. C. Clancy, "Over-the-air deep learning based radio signal classification", *IEEE Journal of Selected Topics in Signal Processing*, vol. 12, no. 1, pp. 168-179, 2018.
- [5] A. K. Nandi and E. E. Azzouz, "Algorithms for automatic modulation recognition of communication signals," *IEEE Transactions on Communications*, vol. 46, no. 4, pp. 431-436, 1998.
- [6] W. B. Chikha, I. Dayoub, W. Hamouda, and R. Attia, "Modulation recognition for mimo relaying broadcasting channels with direct link", *IEEE Wireless Communications Letters*, vol. 3, no. 1, pp. 50-53, 2014.
- [7] A. He, K. K. Bae, T. Newman, J. Gaedert, K. Kim, R. Menon, L. Morales-Tirado, J. Neel, Y. Zhao, J. Reed, and W. Tranter, "A survey

of artificial intelligence for cognitive radios," *Vehicular Technology, IEEE Transactions on*, vol. 59, no. 4, pp. 1578-1592, May 2010.

- [8] M. Alshawaqfeh, X. Wang, A.R. Ekti, M.Z. Shakir, K. Qaraqe, and E. Serpedin, *Cognitive Radio Oriented Wireless Networks: 10th International Conference, CROWNCOM 2015, Doha, Qatar, April 21-23, 2015, Revised Selected Papers*. Cham: Springer International Publishing, 2015, гл. A Survey of Machine Learning Algorithms and Their Applications in Cognitive Radio, pp. 790-801.

ТАБЛИЦА I
СРАВНЕНИЕ ТОЧНОСТИ ИСПЫТАНИЙ.

SNR (дБ)	CNN (%)	ResNet (%)	Начало (%)	LSTM (%)	MentorNet (%)	[11](%)	DDrCNN [14](%)	[21](%)	Предлагаемые (%)
-10	25.71	26.92	23.61	29.56	24.86	30.40	-	-	30.1
-4	54.32	48.53	50.86	58.46	62.45	74.30	64	39	72.3
0	77.64	75.41	73.65	83.19	76.36	90.81	90	68	88.9
4	80.53	80.25	78.87	85.96	78.59	92.84	93	93	92.9
10	81.61	81.69	79.91	87.09	80.16	93.29	95	99	94.9

ТАБЛИЦА II
СРАВНЕНИЕ ВЫЧИСЛИТЕЛЬНОЙ СЛОЖНОСТИ.

	CNN	ResNet	Inception	LSTM	MentorNet	[11]	DDrCNN [14]	Предлагаемый метод
Суммарные параметры	2,830,170	3,424,976	10,142,726	846,376	3,327,400	50,278,762	1,101,448	560,264
Время обучения (сек)/эпоха	44.40	48.90	38.16	91.75	45.54	590.18	12	29.6

- [9] M. Bkassiny, Y. Li, and S. K. Jayaweera, "A survey on machine-learning techniques in cognitive radios," *IEEE Communications Surveys Tutorials*, vol. 15, no. 3, pp. 1136-1159, Third 2013.
- [10] S. Zhou, Z. Yin, Z. Wu, Y. Chen, and Z. Zhao, Nan AU abd Yang, "A robust modulation classification method using convolutional neural networks", *EURASIP Journal on Advances in Signal Processing*, vol. 2019, no. 21, p. 120, Mar 2019. [Online]. Available: <https://doi.org/10.1186/s13634-019-0616-6>
- [11] P. Wu, B. Sun, S. Su, J. Wei, J. Zhao, and X. Wen, "Automatic modulation classification based on deep learning for software-defined radio," *Mathematical Problems in Engineering*, vol. 2020, no. 10, pp. 1-13, Nov 2020.
- [12] Y. Y. Etefagh, M. H. Moghaddam, and S. Eghbalian, "An adaptive neural network approach for automatic modulation recognition", in *2017 51st Annual Conference on Information Sciences and Systems (CISS)*, 2017, стр. 1-5.
- [13] E. Jung, P. Chikontwe, X. Zong, W. Lin, D. Shen, and S. H. Park, "Enhancement of perivascular spaces using densely connected deep convolutional neural network," *IEEE Access*, vol. 7, pp. 18 382-18 391, 2019.
- [14] Y. Wang, M. Liu, J. Yang, and G. Gui, "Data-driven deep learning for automatic modulation recognition in cognitive radios," *IEEE Transactions on Vehicular Technology*, vol. 68, no. 4, pp. 4074-4077, 2019.
- [15] Р. Дилип, Д. Дас и П.К. Бора, "Архитектура cnn на основе плотного выпадения слоев для автоматической классификации модуляции", *Национальная конференция по связи (NCC)*, 2020, с. 1-5.
- [16] K. Anand, S. Majhi, G. Gui, H.-C. Wu, and C. Yuen, "A survey of blind modulation classification techniques for ofdm signals," *Sensors*, vol. 22, no. 1020, pp. 11 734-11 753, 2022.
- [17] Y. TU, Y. LIN, H. ZHA, J. ZHANG, Y. WANG, G. GUI, and S. MAO, "Large-scale real-world radio signal recognition with deep learning," *Chinese Journal of Aeronautics*, vol. 35, no. 9, pp. 35-48, 2022. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1000936121002934>
- [18] H. Y. Alzaq и B. B. Ustundag, "Very-low-snr cognitive receiver based on wavelet preprocessed signal patterns and neural network", *EURASIP Journal on Wireless Communications and Networking*, vol. 2017, no. 1, p. 120, Jul 2017. [Online]. Available: <https://doi.org/10.1186/s13638-017-0902-7>
- [19] T. J. O'Shea, L. Pemula, D. Batra, and T. C. Clancy, "Radio transformer networks: Модели внимания для обучения синхронизации в беспроводных системах", *2016 50-я Асиломарская конференция по сигналам, системам и компьютерам*, 2016, с. 662-666.
- [20] Х. Лю, Д. Янг и А.Е. Гамаль, "Архитектуры глубоких нейронных сетей для классификации модуляции", в *2017 г. 51-я Асиломарская конференция по сигналам, системам и компьютерам*, 2017, стр. 915-919.
- [21] S. Хуанг, Р. Дай, Дж. Хуанг, Й. Яо, Й. Гао, Ф. Нин и З. Фенг, "Автоматическая классификация модуляции с использованием

рекуррентных остатков с регуляровкой".

- сеть", *IEEE Internet of Things Journal*, vol. 7, no. 8, pp. 7795- 7807, 2020.
- [22] J. Gu, Z. Wang, J. Kuen, L. Ma, A. Shahroudy, B. Shuai, T. Liu, X. Wang, G. Wang, J. Cai, and T. Chen, "Recent advances in convolutional neural networks," *Pattern Recognition*, vol. 77, pp. 354-377, 2018. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0031320317304120>
- [23] Y. Y. Sun, W. Zheng, Z. Ren, "Применение конволюционной нейронной сети в обработке изображений", в книге "Применение интеллектуальных систем в мультимодальном анализе информации", V. Sugumaran, A. G. Sreedevi, and Z. Xu, Eds. Cham: Springer International Publishing, 2022, pp. 375-383.
- [24] W. Li, K. Wang, L. You, Z. Huang, "A new deep learning framework for hf signal detection in wideband spectrogram", *IEEE Signal Processing Letters*, vol. 29, pp. 1342-1346, 2022.
- [25] X. Wu, R. He, Z. Sun, and T. Tan, "A light cnn for deep face representation with noisy labels", *IEEE Transactions on Information Forensics and Security*, vol. 13, no. 11, pp. 2884-2896, 2018.
- [26] J. S. H. Al-bayati and B. B. U" stu'ndag", "Evolutionary feature optimization for plant leaf disease detection by deep neural networks," *International Journal of Computational Intelligence Systems*, vol. 13, pp. 12-23, 2020. [Online]. Available: <https://doi.org/10.2991/ijcis.d.200108.001>
- [27] R. J. Cintra, S. Duffner, C. Garcia, and A. Leite, "Low-complexity approximate convolutional neural networks," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 29, no. 12, pp. 5981-5992, 2018.
- [28] X. Li and W. Wang, " Learning discriminative features via weights-biased softmax loss", *Pattern Recognition*, vol. 107, p. 107405, 2020. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S0031320320302089>
- [29] DeepSIG, "Reinventing Wireless with Deep Learning", доступно по адресу: <https://www.deepsig.ai/>.
- [30] L. Lovse, S. Poitras, J. Dobransky, A. Huang, and P.E. Beaulieu, "Следует ли применять принцип парето в качестве метода экономии при артропластике тазобедренного и коленного суставов?". *Journal of Arthroplasty*, vol. 34, no. 12, pp. 2841 - 2845, 2019. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S0883540319307181>